Compilatori

Corso di Laurea in Informatica

Mauro Leoncini

A.A. 2024/2025

Compilatori

1. Nozioni introduttive
   - Informazioni generali
   - Compilatori ed interpreti

2. Struttura del compilatore
   - La struttura attraverso un esempio

Compilatori

Informazioni di contesto

- News importanti e/o urgenti saranno "postate" su Moodle
- Su Moodle verranno anche caricate le slide ed altro materiale didattico (software primariamente)
- MS Teams NON sarà utilizzato
- Ricevimento in presenza: mercoledì ore 11:15. A richiesta su appuntamento (a distanza)
- CFU assegnati: 12 (circa 300 ore di lavoro), ripartiti in due moduli da 6 CFU
- Esame (prima parte): una prova di laboratorio ed un orale con domande che potranno vertere su ogni parte della teoria

Testo per la parte teorica

- Per la prima parte del corso il testo di riferimento (non tutto necessario ma neppure sufficiente) è:

  Aho A.V.; Lam M.S.; Sethi R.; Ullman J.D.
  Compilatori: Principi, tecniche e strumenti
  Pearson Ediz. MyLab. Con aggiornamento online
  https://he.pearson.it/catalogo/1079

- Il libro ancora oggi è noto come il *Dragon Book*, per via delle immagini presenti sulla copertina della prima versione

Laboratorio

- Parallelamente alla teoria, svilupperemo un front-end completo per un semplice *linguaggio funzionale*
- Per questo scopo utilizzeremo l'infrastruttura *LLVM*.
- Per iniziare il riferimento è https://llvm.org/
- Si tenga presente che in molte distribuzioni Linux LLVM è installabile mediante il relativo packet manager
- Materiale didattico per LLVM verrà reso disponibile su Moodle

Obiettivi formativi

Conoscenze su:

- Teoria dei linguaggi formali (linguaggi, espressioni regolari, grammatiche, automi)
- struttura e funzionamento di un compilatore moderno
- tecniche e algoritmi utilizzati nel processo di compilazione

Competenze operative su:

- strumenti automatici di ausilio alla costruzioni di compilatori
- progetto di un front-end completo per un linguaggio semplificato
- soluzioni programmative che possono incidere sulle prestazioni del programma finale

Prerequisiti

- Algoritmi e strutture dati, in particolare ricorsione, grafi, alberi e relativi algoritmi di visita
- Sufficiente padronanza del paradigma ad oggetti e programmazione in C++
- Nota: alcuni elementi del C++ verranno presentati/ripresi in questo stesso insegnamento
- Architettura dei calcolatori. Per questa prima parte è sufficiente un po' di dimestichezza con i linguaggi "tipo assembly"

Compilatori

Che cos'è un compilatore: definizioni e richiami d'uso

- Un compilatore per un linguaggio di programmazione L è un componente di una cosiddetta *toolchain* di programmi il cui obiettivo è creare eseguibili a partire da programmi scritti in L.
- Altri componenti che possono far parte, o che sicuramente fanno parte della toolchain sono
  - precompilatore
  - assemblatore
  - linker (statico e dinamico)
- I componenti della toolchain di solito non vengono invocati esplicitamente, bensì mediante un unico *programma driver*
- Essi sono tuttavia componenti a se stanti utilizzabili anche in modo separato.

La toolchain completa

- Schema dei passi che portano dal sorgente `hw.cpp` (il classico "Hello World") al processo in esecuzione

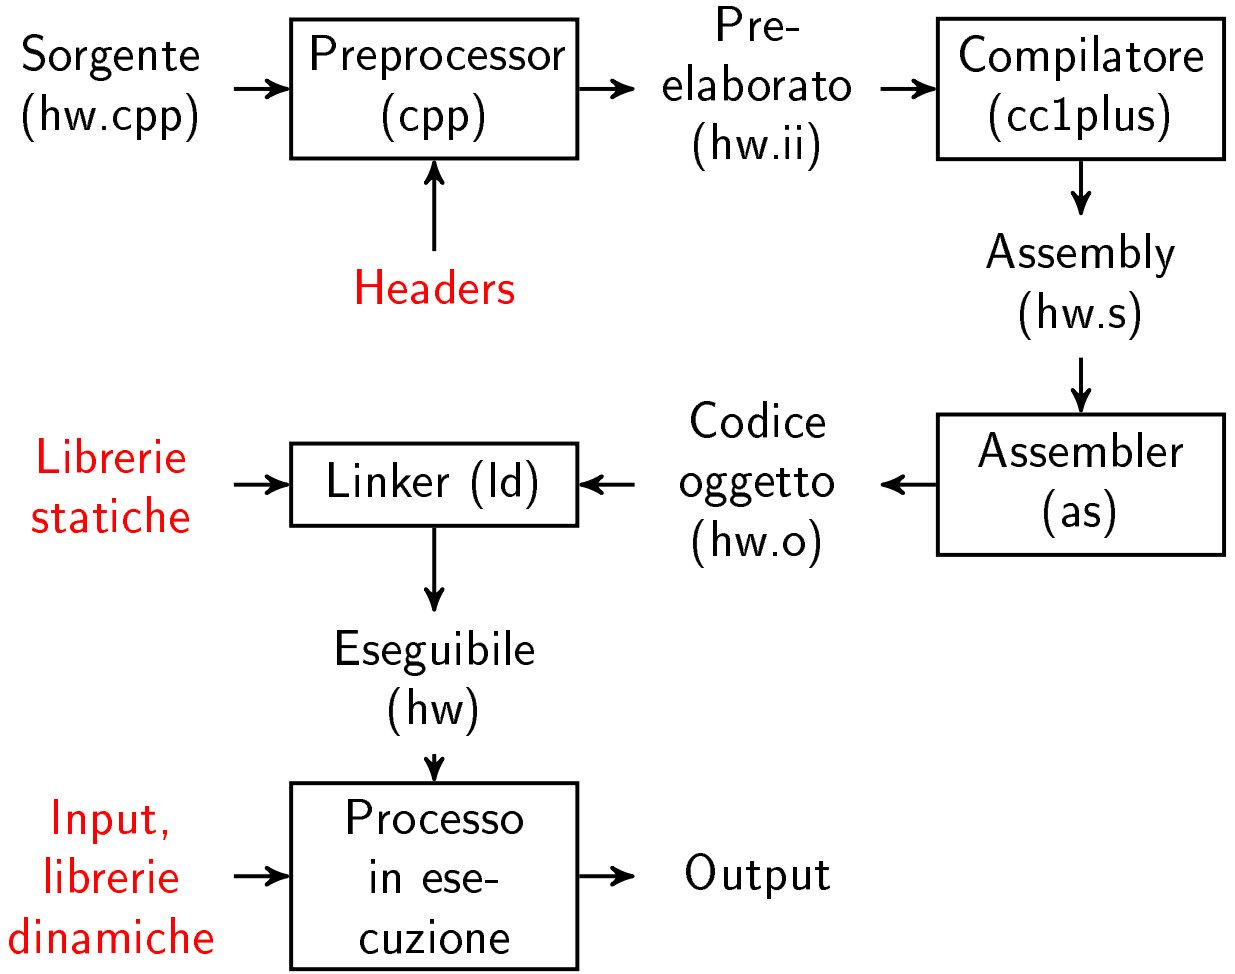

Compilazione con GCC

- *GCC* è un termine abbreviato comune per *GNU Compiler Collection*, una suite in grado di compilare non solo programmi in C/C++ ma anche sorgenti in *Fortran* e *Ada*.
- Originariamente, però, GCC significava *GNU C Compiler* e in effetti facendo riferimento a GCC a volte si intende proprio il compilatore C e/o C++.
- In relazione a questi ultimi linguaggi, e all'ambiente Linux, gli elementi della toolchain GCC sono riferiti nel modo seguente:
  - *cpp* è nome con cui si indica il preprocessor C/C++;
  - *cc1*/*cc1plus* è il nome del compilatore vero e proprio;
  - *as* è il nome del programma assemblatore;
  - *ld* è il nome del linker (linking statico e dinamico).
- Normalmente si usa un programma driver (es. g++) ma è istruttivo per una volta procedere all'invocazione esplicita dei programmi della toolchain

Uso dei programmi della toolchain

- Preprocessing:
  `> cpp -o hw.ii hw.cpp`
- Compilazione:
  `> cc1plus -o hw.s hw.ii 2>/dev/null`
- "Assemblaggio":
  `> as -o hw.o hw.s`
- Linking:
  `> ld ...`

Note

1. `cc1plus` quasi certamente non è nel search path. Nelle distribuzioni Debian si trova "attualmente" (settembre 2024) in: `/usr/libexec/gcc/x86_64-linux-gnu/XX/` (`XX` indica la release)
2. I parametri da passare al linker sono numerosi. Nella prossima slide vediamo come determinarli

I parametri del linker

- Per determinarli, usiamo il driver g++ con l'opzione `-v`
  `> g++ -v -o hw hw.o`
- Il driver invoca il linker usando il comando `collect` (o `collect2`), invocazione che viene evidenziata in fondo alla lunga sequenza di dati prodotti
- I parametri da inserire nella chiamata esplicita di `ld` sono proprio quelli utilizzati nella chiamata di `collect`
- È di norma possibile escludere i plugin e usare i parametri a partire da `-build-id`

```
> ld -build-id -eh-frame-hdr -m elf_x86_64 \
> -hash-style=gnu -as-needed \
> -dynamic-linker /lib64/ld-linux-x86-64.so.2 \
>  ...
> /usr/lib/x86_64-linux-gnu/crtn.o
```

Compilatori vs intepreti

- Un diverso modo per "implementare" un linguaggio di programmazione è costituito dall'*interpretazione*.
- Un interprete fornisce l'impressione di eseguire direttamente il programma in linguaggio sorgente.
- I seguenti schemi permettono di avere una comprensione immediata delle differenze fra le due implementazioni di un linguaggio, compilata e interpretata.
- Rispetto a quanto visto, lo schema di compilazione astrae il contributo dei singoli programmi della toolchain.

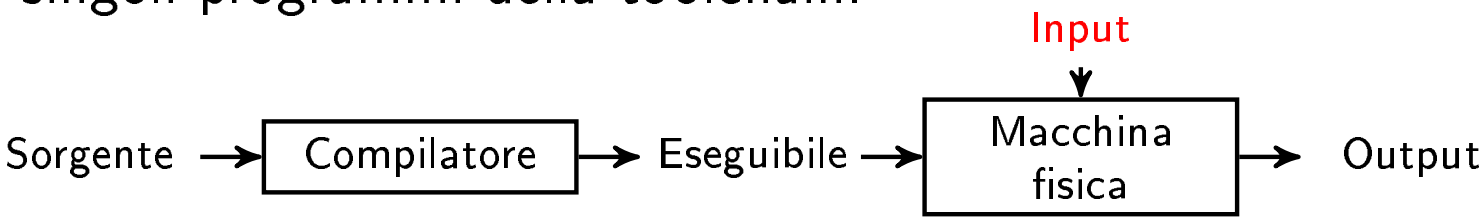

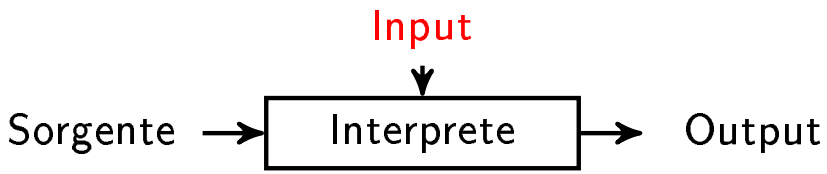

Realizzazioni alternative di un inteprete

- Un *interprete puro* legge il testo sorgente di un programma, lo analizza e lo esegue mentre procede.
- Questo procedimento è inefficiente: l'interprete spende infatti molto tempo nell'analisi dell'input (testuale).
- Un tale interprete deve riconoscere e analizzare ogni espressione nel testo di partenza ogni volta che la incontra, in modo da eseguire ciò che essa prescrive.
- Questa alternativa "pura" è stata utilizzata per l'implementazione di pochissimi linguaggi (tra cui il più importante è il *Lisp* originale).
- In generale, un'implementazione interpretata include anche un traduttore che è essenzialmente identico al *front-end* di un compilatore.
- Il risultato prodotto dal traduttore può essere più o meno vicino alla macchina fisica ed è proprio tale linea di demarcazione che caratterizza i diversi "interpreti".

Modello PERL

- Il linguaggio *PERL* (*Practical Extraction and Report Language*) è il paradigma di un'implementazione in cui la parte iniziale di traduzione produce una rappresentazione *ad albero* del programma, noto come *Abstract Syntax Tree* (*AST*).
- L'interpretazione del programma potrebbe essere eseguita essenzialmente mediante una visita in *ordine posticipato* dell'AST, utilizzando opportune strutture dati a supporto.
- Per ragioni di efficienza, l'interprete PERL esegue dapprima svariate ottimizzazioni, ad esempio per rendere più efficiente l'attraversamento dell'albero.
- Alcune porzioni di codice, che dovranno essere eseguite più volte, vengono anche tradotte in codice macchina.

Modello Java

- La tipica implementazione di Java (ma anche di Python) prevede che il traduttore produca codice eseguibile da una *Virtual Machine* (*VM*).
- Tale codice, chiamato *bytecode*, può dunque essere visto come il linguaggio macchina della VM.
- Nel caso di PERL la percezione dell'utente è analoga a quella che si ha nell'interpretazione pura: traduttore e inteprete appaiono come un unico programma e l'esecuzione avviene in risposta al singolo comando.
- Nel caso di Java, invece, la traduzione in linguaggio bytecode e l'interpretazione avvengono in momenti distinti.
- È noto infatti che l'implementazione di Java consiste di due moduli software: il *compilatore Java* e il cosiddetto *Java Runtime Environment* (*JRE*)

Compilatori

I moduli del compilatore

- Da ora in avanti il termine *compilatore* si riferirà solo al modulo che effettua la traduzione da sorgente ad una qualche rappresentazione intermedia (quindi non la toolchain completa).
- Un compilatore è strutturato in tre *moduli*
  1. front-end
  2. middle-end
  3. back-end
- Il *front-end* è la parte del compilatore *specializzata nel linguaggio*.
- Il front-end opera sul programma sorgente e produce una sua *rappresentazione intermedia*, indipendente dal linguaggio e dalla macchina.
- Il *middle-end* esegue un'ottimizzazione del codice intermedio machine-independent.
- Infine il *back-end* produce il codice per l'architettura target (eseguendo altre specifiche ottimizzazioni).

Le fasi della compilazione

- La seguente figura è tratta dal *Dragon Book*
- Il front/middle/back-end è composto di 4/1/2 fasi

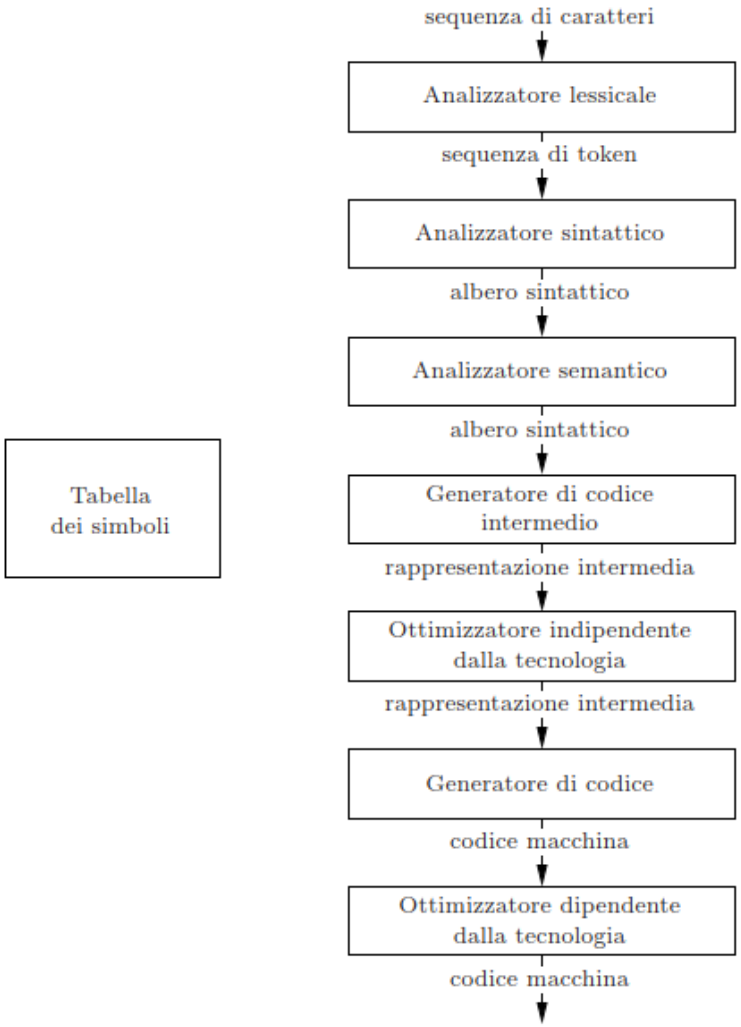

Esempio di traduzione di un'istruzione

- Dal Dragon Book: fasi applicate ad una instruzione

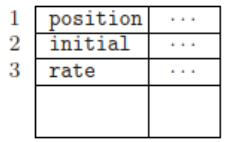

1	position	···
2	initial	···
3	rate	···

Tabella dei simboli

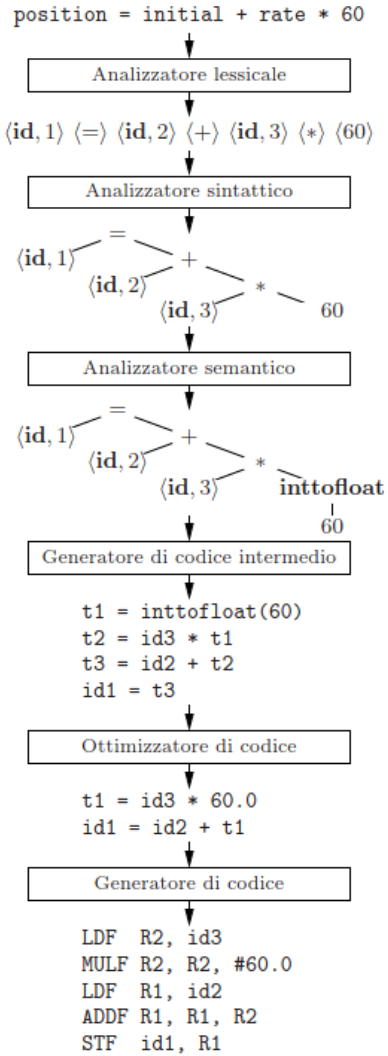

Struttura del front-end

- I moduli che compongono il front-end di un compilatore e le loro interazioni sono riassunte nel seguente schema
- La tabella dei simboli è un dizionario (tipicamente implementato come tabella hash) che memorizza i simboli via via incontrati nell'analisi del sorgente e le loro caratteristiche

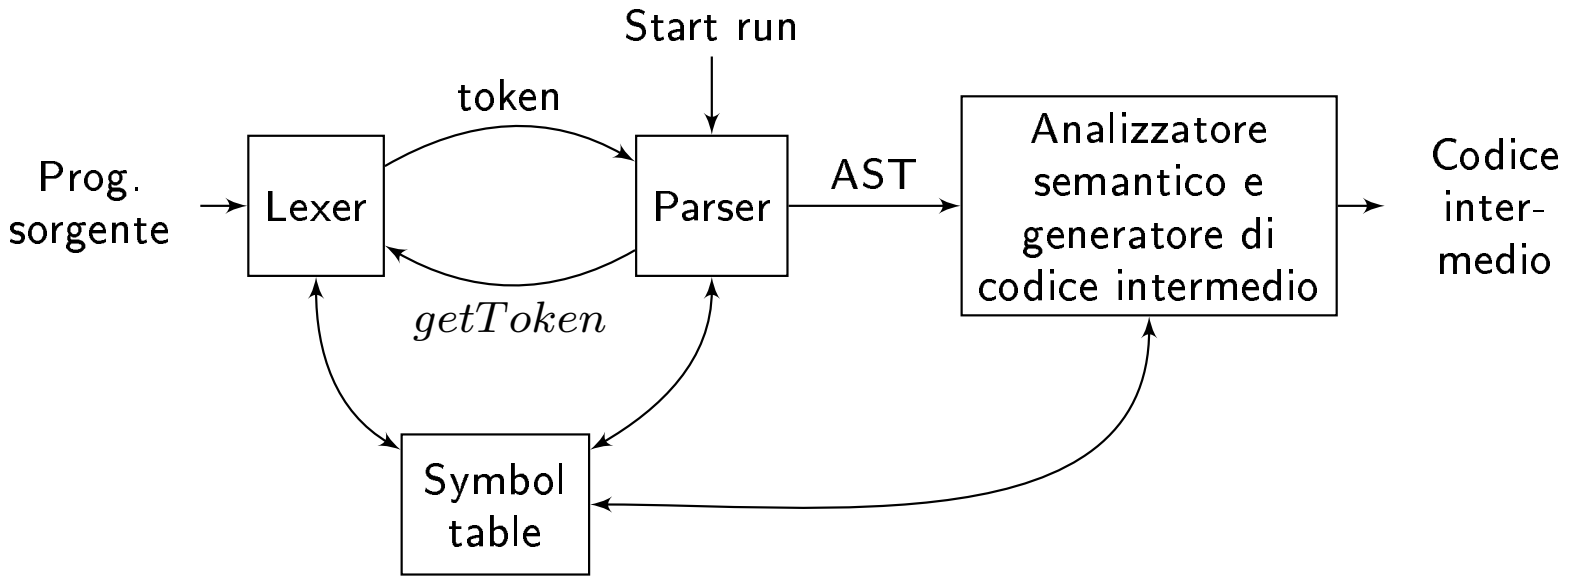

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?

Per finire questo primo set di slide...

- Cosa si intende con il termine *type checking*?
- ... e cosa significano le qualifcazioni type checking *statico* e type checking *dinamico*?
- Cosa sono le *regole di scope* (*scoping rules*)?
- Sai illustrare/descrivere i concetti di ambiente e memoria?
- Conosci un linguaggio in cui il programmatore ha visibilità del solo ambiente?
- Cosa sono i c.d. ℓ-value e r-value?
- Se `x` è una variabile intera e `p` è un puntatore ad intero, è legale scrivere `p = &x;`? e `&x = p;`?
- Sai implementare queste strutture: *stack*, *dizionario*, *albero binario/n-ario*?