# Compilatori

Corso di Laurea in Informatica

Mauro Leoncini

A.A. 2024/2025

### Linguaggi e compilatori

- 🚺 Analisi sintattica (PARTE TERZA): Parsing shift-reduce
  - Generalità sul parsing bottom-up
  - Architettura di un parser LR
  - Parsing SLR(1)

### Compilatori

- 💶 Analisi sintattica (PARTE TERZA): Parsing shift-reduce
  - Generalità sul parsing bottom-up
  - Architettura di un parser LR
  - Parsing SLR(1)

### Elementi generali

- Un parser generico di tipo bottom-up procede operando una sequenza di riduzioni a partire dalla stringa di input  $\alpha_0=\alpha$  e cercando di risalire così all'assioma iniziale.
- Al generico passo di riduzione il parser individua, nella stringa corrente  $\alpha_i$ , un'opportuna sottostringa  $\beta$  che corrisponde alla parte destra di una produzione  $A \to \beta$  e sostituisce  $\beta$  con A, così riducendo  $\alpha_i$  ad  $\alpha_{i+1}$ :

$$\alpha_i = \gamma \beta \delta, \qquad \alpha_{i+1} = \gamma A \delta$$

- Il processo termina con successo se, per un opportuno valore di i, risulta  $\alpha_i = \mathcal{S}$ .
- Nell'ambito del processo di riduzione il parser può costruire (dal basso verso l'alto) un albero di derivazione e/o produrre direttamente codice.

4 D > 4 A > 4 B > 4 B > B = 9000

# Parsing "Shift-reduce"

- Un parser shift-reduce è un parser di tipo bottom-up che fa uso di uno stack nel quale vengono memorizzati simboli (terminali o non terminali) della grammatica.
- Il nome deriva dal fatto che le due operazioni fondamentali eseguite del parser sono dette, appunto, shift (spostamento) e reduce (riduzione).
  - L'operazione shift legge un simbolo dallo stream di input e lo inserisce sullo stack.
  - L'operazione reduce sostituisce sullo stack gli ultimi k simboli inseriti (poniamo  $X_1,\ldots,X_k$ , con  $X_k$  sulla cima) con il simbolo A, naturalmente se esiste la produzione  $A\to X_1\ldots X_k$ .
- Le sole altre operazioni che il parser esegue sono: accettare l'input o segnalare una condizione di errore.

#### Riduzioni e shift

- Per un parser di questo tipo la difficoltà consiste proprio nel decidere quando operare la riduzione e quando invece è necessario procedere con uno shift.
- Infatti, non è sempre vero che, quando sullo stack c'è la parte destra di una produzione, bisogna operare la riduzione.
- Un esempio relativo alla "solita" grammatica

$$\begin{array}{ccc} E & \rightarrow & E+T \mid T \\ T & \rightarrow & T \times F \mid F \\ F & \rightarrow & \mathbf{n} \mid (E) \end{array}$$

chiarisce questo punto.

### Esempio

- ullet Consideriamo il problema del riconoscimento della stringa  ${f n} imes {f n}$ .
- La seguente tabella illustra il contenuto dello stack e l'input ancora da leggere se venisse applicato l'approccio "greedy" (errato) appena delineato.

Indice $i$	Stack	Input	Azione	$\alpha_i$
0	\$	$n \times n$ \$	shift	$n \times n$ \$
0	\$ <u>n</u>	$\times$ n $\$$	reduce	$n \times n$ \$
1	\$ <u>F</u>	$\times$ n $\$$	reduce	$F \times \mathbf{n}\$$
2	\$ <u>T</u>	$\times$ n $\$$	reduce	$T \times \mathbf{n}\$$
3	\$E	$\times$ n $\$$	shift	$E \times \mathbf{n}\$$
3	$E\times$	n\$	shift	$E \times \mathbf{n}\$$
3	$\$E \times \mathbf{\underline{n}}$	\$	reduce	$E \times \mathbf{n}\$$
4	$\$E \times \underline{F}$	\$	reduce	$E \times F$ \$
5	$$E \times \underline{T}$	\$	reduce	$E \times T$ \$
6	$$E \times E$	\$	error	$E \times E$ \$

# Handle (maniglie)

- Un parser di tipo shift-reduce deve individuare, come sottostringhe da ridurre a non terminale, esattamente quelle sequenze (e quelle produzioni) usate nella derivazione canonica destra.
- Tali sequenze devono inoltre essere individuate "nell'ordine giusto", e cioè l'ordine rovesciato rispetto alla corrispondente derivazione canonica destra.
- Queste sequenze (ma meglio sarebbe dire "produzioni") vengono chiamate handle (maniglie), di modo che il problema centrale della realizzazione di un tale parser può essere espresso sinteticamente come il problema di individuare le handle.

#### Esempio corretto

ullet La corretta riduzione per la stringa  ${f n} imes {f n}$  è indicata di seguito

Indice $i$	Stack	Input	Azione	$\alpha_i$
0	\$	$n \times n$ \$	shift	$n \times n$ \$
0	\$ <u>n</u>	$\times$ n $\$$	reduce	$n \times n$ \$
1	$\frac{\$F}{T}$	$\times$ n $\$$	reduce	$F \times \mathbf{n}\$$
2	T	$\times$ n $\$$	shift	$T \times \mathbf{n}\$$
2	$T \times$	n\$	shift	$T \times \mathbf{n}\$$
3	$T \times \underline{\mathbf{n}}$	\$	reduce	$T \times \mathbf{n}\$$
4	$\underline{T} \times F$	\$	reduce	$T \times F$ \$
5	\$ <u>T</u>	\$	reduce	T\$
6	\$E	\$	accept	E\$

• Si noti che, leggendo l'ultima colonna dal basso verso l'alto, in corrispondenza delle operazioni "reduce" si rivela la derivazione canonica destra di  $\mathbf{n} \times \mathbf{n}$ .

#### Osservazioni

- Ad ogni dato istante, l'attuale forma di frase (la stringa  $\alpha_i$ ) si trova "parte sullo stack e parte ancora sullo stream di input".
- Più precisamente, se lo stack contiene una stringa  $\alpha\beta_1$  (dal basso verso l'alto) e lo stream di input contiene la stringa  $\beta_2\gamma$ , allora la forma di frase "corrente" nella derivazione destra è  $\alpha\beta_1\beta_2\gamma$ .
- Se la prossima handle è la produzione  $A o eta_1 eta_2$  allora:
  - se  $\beta_2 = \epsilon$  allora la prossima mossa è la riduzione;
  - se  $\beta_2 \neq \epsilon$  allora la prossima mossa è uno shift;
- Se la prossima handle non è  $A \to \beta_1 \beta_2$  allora il parser esegue uno shift o dichiara errore (come vedremo).

### Il cuore computazionale del problema

- La difficoltà di progettazione di un parser shift-reduce parser sta tutta nella capacità di riconoscere quando è corretto operare uno shift e quando invece è corretto operare una riduzione.
- Il problema coincide con quello di determinare esattamente le handle.
   Infatti, se fossimo in grado di risolvere quest'ultimo sapremmo sempre quando operare uno shift e quando eseguire una riduzione.
- Dovremmo infatti "ridurre" quando e solo quando una maniglia appare sulla cima dello stack.
- Sfortunatamente ci sono grammatiche per le quali il paradigma shift-reduce non è applicabile, ad esempio grammatiche ambigue.

### Osservazione)

- Si noti, di passaggio, che se considerassimo derivazioni canoniche sinistre, anziché destre, non potremmo contare sulla proprietà che la (o una) handle prima o poi si trovi sulla cima dello stack
- Si consideri il solito semplice esempio

Indice $i$	Stack	Input	Azione	Stringa $lpha_i$
0	\$	n + <u>n</u> \$	shift	n+n\$
0	\$n	+ <u>n</u> \$	shift	n+n\$
0	n+	<u>n</u> \$	shift	n+n\$
0	\$n + <u>n</u>	\$	reduce	n+n\$
1	$n + \underline{F}$	\$	reduce	n + F\$
2	$\$ \underline{\mathbf{n}} + T$	\$	reduce	n + T\$
3	$\$\underline{F} + T$	\$	reduce	F + T\$
4	$\underline{\$T} + T$	\$	reduce	T + T\$
5	$\underline{\$E+T}$	\$	reduce	E+T\$
6	$\$\overline{E}$	\$	accept	E\$

# Prefissi ammissibili (viable prefix)

- Supponiamo ora di disporre già di un parser che non si lascia mai "sfuggire" la handle appena questa compare sulla cima dello stack e dunque che è sempre in grado di ricostruire la corretta derivazione canonica destra di una stringa del linguaggio
- Questo vuol dire che, per ogni data forma di frase  $\alpha_i$ , la parte che sta sullo stack è un prefisso di  $\alpha_i$  che non oltrepassa mai la handle stessa
- Si faccia riferimento all'esempio riportato nella slide 9 per visualizzare la situazione.
- Vediamo alcuni casi
  - ullet Con la forma di frase  $T \times F$  la handle è sulla cima dello stack e coincide con la forma di frase
  - Con la forma di frase  $T \times \mathbf{n}$  la handle è (indice i = 2) parte sullo stack e parte ancore nell'input ovvero (i = 3) sulla cima dello stack

# Prefissi ammissibili (viable prefix)

- Per un tale parser, i prefissi delle varie forme di frase che si possono leggere via via sullo stack sono detti ammissibili
- ullet Senza far riferimento allo stack, possiamo dire che, in una derivazione canonica destra, i *prefissi ammissibili* sono quei prefissi di una qualsiasi forma di frase lpha che non superano l'ultimo carattere della handle in lpha
- Se la grammatica è ambigua, la definizione va però corretta perchè potrebbero esserci più handle e in tal caso il prefisso è ammissibile in  $\alpha$  se non supera la handle più a destra in  $\alpha$ . Un esempio:

Qui il prefisso E+E+ è ammissibile per la forma di frase  $E+E+{\rm id}$  anche se "supera" la handle E+E perché nella forma di frase c'è ancora una handle più a destra

 ✓ □ > ✓ ⊕ > ✓ ⊕ > ✓ ⊕ > ✓ ⊕ > ✓ ⊕

 Mauro Leoncini
 Compilatori
 Anno Accademico 2024/25 14 / 69

### Compilatori

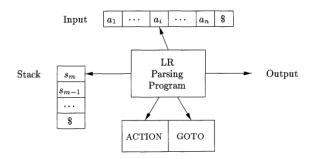
- 💶 Analisi sintattica (PARTE TERZA): Parsing shift-reduce
  - Generalità sul parsing bottom-up
  - Architettura di un parser LR
  - Parsing SLR(1)

#### Parser LR

- Si tratta di una classe di parser di tipo shift-reduce che analizzano l'input da sinistra a destra (L) e che cercano di ricostruire una derivazione canonica destra (R) per l'input medesimo
- La diversa capacità di effettuare il parsing dipende dall'informazione contenuta in apposite tabelle di parsing che guidano il comportamento del programma.
- In questi appunti analizzeremo un solo tipo di parser LR, il più semplice, che prende (non a caso) il nome di (parser) SLR(1).
- Per prima cosa vedremo però la "program structure" comune.

## Struttura di un parser LR

• Un parser LR è caratterizzato da un programma di controllo che ha accesso ad uno stack e ad una tabella di parsing, oltre che a opportuni supporti di input e output.



### Struttura di un parser LR (continua)

- Le tabelle prescrivono il comportamento del programma di controllo in funzione del contenuto dello stack e dei primi k caratteri presenti in input (per noi k=1).
- Lo stack, a differenza dei parser shift-reduce visti precedentemente, contiene stati anziché simboli.
- Tuttavia, come vedremo, ad ogni stato è associato univocamente un simbolo della grammatica (l'inverso non è necessariamente vero).
- Come nel caso generico di parser shift-reduce, possiamo quindi ricostruire la forma di frase corrente (di una derivazione canonica destra) utilizzando i simboli memorizzati sullo stack concatenati con i simboli ancora sullo stream di input.

### Tabelle di parsing

- Le tabelle di parsing di un parser LR hanno un numero di righe pari al numero di stati dell'automa che costituisce il controllo.
- Le colonne sono indicizzate dai simboli terminali e non terminali. Le colonne relative ai terminali formano quella che viene detta "parte ACTION" della tabella, mentre le altre formano la "parte GOTO".
- Nella parte action sono previste 4 tipi di azioni:
  - avanzamento di un carattere sullo stream di input e inserimento di uno stato in cima allo stack;
  - esecuzione di una riduzione;
  - accettazione dell'input;
  - rilevamento di un errore.
- La parte GOTO prescrive stati da inserire nello stack.

#### Funzionamento del parser

- Il funzionamento del parser è definito come segue.
- Inizialmente, lo stack contiene un solo stato (lo stato iniziale, naturalmente).
- ullet Al generico passo, sia q lo stato in cima allo stack e x il prossimo carattere in input.
- Se ACTION[q, x] =shift r, il parser avanza il puntatore di input e inserisce lo stato r sullo stack.
- Se  $ACTION\left[q,x\right]=$  reduce i, il parser utilizza la i-esima produzione (secondo una numerazione arbitraria ma prefissata). Più precisamente, se  $A \rightarrow \alpha$  è tale produzione, il parser rimuove  $k_i = |\alpha|$  stati dallo stack e vi inserisce lo stato  $GOTO\left[q',A\right]$  dove q' è lo stato sulla cima dello stack dopo le  $k_i$  rimozioni.
- Il parser si arresta in seguito ad accettazione o errore.

### Esempio

 Consideriamo la grammatica che genera sequenze di parentesi bilanciate:

$$egin{array}{lll} S & 
ightarrow & (S)S & {
m Produzione 1} \ S & 
ightarrow & \epsilon & {
m Produzione 2} \ \end{array}$$

e consideriamo la seguente tabella di parsing (di cui vedremo più avanti la costruzione):

Stato	ACTION			GOTO
Stato	(	)	\$	S
0	shift 2	reduce 2	reduce 2	1
1			accept	
2	shift 2	reduce 2	reduce 2	3
3		shift 4		
4	shift 2	reduce 2	reduce 2	5
5		reduce 1	reduce 1	

Consideriamo il comportamento del parser su input ()().

### Esempio (continua)

Stack	Input	Azione
\$0	()()\$	shift 2
\$02	)()\$	reduce $S  ightarrow \epsilon$
\$023	)()\$	shift 4
\$0234	()\$	shift 2
\$02342	)\$	reduce $S  ightarrow \epsilon$
\$023423	)\$	shift 4
\$0234234	\$	reduce $S  ightarrow \epsilon$
\$02342345	\$	reduce $S  o (S)S$
\$02345	\$	reduce $S  o (S)S$
\$01	\$	accept

- Si ricordi che la riduzione con  $S \to (S)S$  prima rimuove 4 stati dallo stack, quindi inserisce lo stato GOTO[q',S], dove q' è lo stato che rimane in cima allo stack dopo le rimozioni.
- ullet Analogamente, la riduzione con  $S 
  ightarrow \epsilon$  rimuove 0 stati.

### Compilatori

- 💶 Analisi sintattica (PARTE TERZA): Parsing shift-reduce
  - Generalità sul parsing bottom-up
  - Architettura di un parser LR
  - Parsing SLR(1)

# Parsing SLR(1)

- Il primo tipo di parser LR che analizziamo è detto  $Simple\ LR$  parser (o semplicemente SLR).
- È caratterizzato da tabelle di parsing di relativamente semplice costruzione (da cui il nome) ma che danno minori garanzie sulla possibilità di analisi di grammatiche libere.
- In altri termini, ci sono diverse grammatiche libere di interesse che non possono essere analizzate con parser SLR (e, segnatamente, SLR(1)).
- ullet Si tratta comunque di un caso utile per capire la "logica" di un parser LR.

# Item LR(0)

- Per comprendere come un parser SLR(1) prende le proprie decisioni (ovvero per capire come viene costruita la tabella di parsing) iniziamo ad introdurre il concetto di *item* LR(0) per una grammatica G
- Un  $item\ LR(0)$  (o semplicemente item) di G è una produzione di G in cui nella parte destra viene inserito un punto.
- ullet Una produzione in cui la parte destra contiene k simboli (terminali o non terminali) dà origine a k+1 item in cui i punti sono inseriti all'inizio, dopo il primo simbolo,...,dopo l'ultimo simbolo
- Ad esempio, gli item associati alla produzione  $S \to (S)S$  della grammatica che riconosce le sequenze bilanciate di parentesi sono:  $S \to \cdot (S)S, \ S \to (\cdot S)S, \ S \to (S \cdot S)S$ .
- ullet Ad una produzione tipo  $S 
  ightarrow \epsilon$  è associato il solo item  $S 
  ightarrow \cdot \cdot$

## Item LR(0)

- Intuitivamente, il punto inserito in una produzione indica la posizione alla quale siamo arrivati nel processo di riconoscimento della parte destra della produzione stessa.
- Ad esempio, l'item  $S \to (S) \cdot S$  indica che nell'input abbiamo riconosciuto una stringa generabile a partire da (S) e che ci "attendiamo" di riconoscere una stringa generabile da S.
- Un item con il puntino in fondo indica quindi che il processo di riconoscimento della parte destra nell'input è completato e dunque che (presumibilmente...) si può operare la riduzione.
- $\bullet$  Un'opportuna collezione di insiemi di item LR(0) fornisce i dati fondamentali per la costruzione di un automa utilizzabile per prendere le decisioni di parsing
- ullet Nel caso in questione, in ordine alla costruzione del parser SLR(1), la collezione viene chiamata collezione canonica di item LR(0)

Mauro Leoncini Compilatori Anno Accademico 2024/25 26/69

## AFND LR(0)

- Utilizzando gli item costruiamo ora un automa non deterministico in cui gli stati sono proprio gli item mentre le transizioni sono così determinate:
  - Se uno stato s è associato all'item  $\alpha \cdot X\beta$ , allora si inserisce una transizione etichettata X da s allo stato t associato all'item  $\alpha X \cdot \beta$
  - Se il simbolo X è un non terminale, si inserisce una transizione etichettata  $\epsilon$  verso tutti gli stati t associati ad item in cui X è la testa della produzione
- Per esemplificare la costruzione, utilizziamo la seguente semplice grammatica  $G_{AB}$ , di valenza solo "didattica" (già aumentata con la produzione  $A' \to A$ )

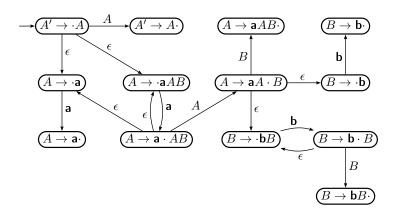
$$A' \rightarrow A$$

$$A \rightarrow \mathbf{a} \mid \mathbf{a}AB$$

$$B \rightarrow \mathbf{b} \mid \mathbf{b}B$$

### AFND LR(0)

 Se consideriamo tutti gli stati come stati finali, allora l'automa riconosce tutti e soli i prefissi ammissibili della grammatica



### AFND LR(0)

• A titolo di esempio, consideriamo la derivazione canonica destra

$$A' \Rightarrow \underline{A} \Rightarrow \underline{\mathsf{a}} A B \Rightarrow \mathsf{a} A \underline{\mathsf{b}} B \Rightarrow \mathsf{a} A \underline{\mathsf{b}} \underline{\mathsf{b}} \Rightarrow \mathsf{a} \underline{\mathsf{a}} \underline{\mathsf{b}} \underline{\mathsf{b}}$$

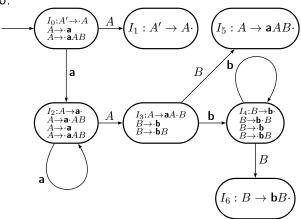
- Per ogni forma di frase, si può verificare che tutti i prefissi che non si estendono a destra della handle (indicata, al solito, con la sottolineatura) sono riconosciuti dall'automa
- Viceversa, nessuna sequenza di transizioni dell'automa è etichettata dai prefissi aab e (a maggior ragione) aabb, che non sono ammissibili
- Come ulteriore esempio, si provi a verificare che l'automa riconosce i prefissi ammissibili (e solo quelli) presenti nella derivazione canonica destra della stringa a<sup>4</sup>b<sup>3</sup>.

# AFD LR(0)

- Utilizzando la *subset construction*, vista a suo tempo, possiamo poi realizzare l'automa deterministico equivalente
- Nell'automa deterministico gli stati sono costituiti non da singoli item bensì da collezioni di item
- Lo stato iniziale, sulla base di quanto "prescritto" dalla subset construction, è la chiusura dello stato dell'AFND corrispondente
- E poiché tutti gli stati dell'AFND sono finali, tali saranno anche tutti gli stati del corrispondente AFD

### AFD LR(0)

• L'automa deterministico LR(0) per la grammatica  $G_{AB}$  è illustrato di seguito:



## AFD LR(0)

- Si noti che l'intersezione di due stati, ovvero di due collezioni di item, può non essere vuota.
- ullet Ad esempio, l'item  $B 
  ightarrow \cdot {f b}$  è presente nella collezione  $I_3$  ma anche nella  $I_5$
- Sono le collezioni nel loro insieme che devono essere distinte
- Naturalmente, in casi particolari un item può formare uno stato/collezione da solo.
- Questo è il caso, ad esempio, dell'item  $B \to \mathbf{b}B$ .
- Per una generica grammatica, si definiscono kernel item l'item iniziale  $\mathcal{S}' \to \mathcal{S}$  e tutti gli item che non hanno il punto all'inizio
- Nonkernel item sono tutti gli altri, ovvero gli item che hanno il punto all'inizio, ad eccezione di  $\mathcal{S}' \to \cdot \mathcal{S}$

### Un secondo esempio

Per la grammatica "aumentata"

$$S' \rightarrow S$$

$$S \rightarrow (S)S \mid \epsilon$$

sono definiti i seguenti insiemi di item:

$$I_{0}: S' \to \cdot S \qquad I_{3}: S \to (S \cdot)S$$

$$S \to \cdot (S)S$$

$$S \to \cdot \qquad I_{4}: S \to (S) \cdot S$$

$$S \to \cdot (S)S$$

$$I_{1}: S' \to S \cdot \qquad S \to \cdot$$

$$I_{2}: S \to (\cdot S)S \qquad I_{5}: S \to (S)S \cdot S \to \cdot$$

$$S \to \cdot (S)S \qquad S \to \cdot$$

### Costruzione "diretta" degli insiemi LR(0)

- L'automa deterministico LR(0) e, segnatamente, le collezioni item che ne costituiscono gli stati, possono essere costruiti senza passare prima per l'automa non deterministico
- Ne diamo ora una descrizione informale
- La collezione iniziale  $I_0$  contiene l'item  $\mathcal{S}' \to \mathcal{S}$  e tutti gli item ottenuti dalle produzioni di  $\mathcal{S}$  inserendo il punto all'inizio.
- Nell'ultimo esempio considerato, si aggiungono a  $S' \to S'$  due soli item (perché ci sono due produzioni relative ad S).
- ullet Si procede poi ricorsivamente. Per ogni collezione  $I_j$  già formata:
- si considerano tutti i simboli della grammatica immediatamente alla destra del punto in item di  $I_i$ .
- Per ogni simbolo così individuato, si forma un gruppo  $I_k$  che contiene, inizialmente, gli item ottenuti spostando il punto alla destra del simbolo considerato.

4日ト 4周ト 4三ト 4三ト 三 めのべ

# Come costruire gli insiemi LR(0) (continua)

• Ad esempio, fra gli item di  $I_0$  (per la grammatica appena considerata) ci sono due soli simboli alla destra del punto, S e (:

$$I_0: S' \to \cdot S$$

$$S \to \cdot (S)S$$

$$S \to \cdot$$

• Per ognuno di essi si creano due nuovi insiemi,  $I_1$  e  $I_2$ , che contengono <u>inizialmente</u> un solo item ciascuno:

$$I_1: S' \to S$$

$$I_2: S \to (\cdot S)S$$

# Come costruire gli insiemi LR(0) (continua)

- Se il nuovo insieme  $I_k$  appena inizializzato contiene item in cui il punto precede un simbolo non terminale A, si aggiungono ad  $I_k$  tutti gli item ottenuti dalle produzioni di A inserendo il punto all'inizio.
- ullet Quest'ultima operazione è detta *chiusura* dell'insieme  $I_k$ .
- Continuando l'esempio precedente, poiché l'insieme  $I_2$  contiene l'item  $S \to (\cdot S)S$ , ad esso si aggiungono gli item  $S \to \cdot (S)S$  e  $S \to \cdot$ :

$$I_2: \quad S \to (\cdot S)S$$

$$S \to \cdot (S)S$$

$$S \to \cdot$$

 Il procedimento termina quando non ci sono più insiemi di item da considerare.

#### Funzioni CLOSURE e GOTO

- Il procedimento appena descritto (in maniera alquanto discorsiva) può essere sinteticamente ricapitolato facendo uso delle due funzioni CLOSURE e GOTO, che lavorano su insiemi di item.
- Dato un insieme di item I, CLOSURE(I) si ottiene aggiungendo (ricorsivamente) ad I item del tipo  $B \to \cdot \gamma$  sotto le seguenti condizioni:
  - in I esista inizialmente un item del tipo  $A \to \alpha \cdot B\beta$ , oppure,
  - ullet ad I sia già stato aggiunto un item del tipo  $A 
    ightarrow \cdot B eta$  .
- Il procedimento termina quando non si possono più aggiungere item sulla base delle precedenti regole.

## Funzione CLOSURE(I)

```
SetOfItems CLOSURE(I) { J = I; repeat for ( each item A \to \alpha \cdot B\beta in J ) for ( each production B \to \gamma of G ) if ( B \to \cdot \gamma is not in J ) add B \to \cdot \gamma to J; until no more items are added to J on one round; return J; }
```

#### Funzioni CLOSURE e GOTO (continua)

- Se I è un insieme di item e X un simbolo della grammatica GOTO(I,X) è un insieme di item, che chiameremo J, calcolato nel seguente modo:
  - inizialmente di pone  $J = \{\}$ ;
  - per ogni item  $A \to \alpha \cdot X\beta$  in I, si aggiunse a J l'item  $A \to \alpha X \cdot \beta$ ;
  - infine si pone  $J \leftarrow CLOSURE(J)$ .

#### Insiemi di item LR(0)

 Utilizzando le funzione CLOSURE e GOTO possiamo definire con precisione il calcolo degli insiemi di item per una grammatica aumentata.

```
1: C \leftarrow \{CLOSURE(\{\mathcal{S}' \rightarrow \cdot \mathcal{S}\})\}

2: repeat

3: for each I \in C do

4: for each X \in \mathcal{T} \cup \mathcal{N} do

5: if GOTO(I, X) \neq \{\} \& GOTO(I, X) \notin C then

6: C \leftarrow C \cup \{GOTO(I, X)\}

7: until No new state is added to C
```

• Consideriamo la seguente grammatica (aumentata) che genera il linguaggio  $\{a^nb^n|n\geq 1\}$ :

$$\begin{array}{ccc} S' & \to & S \\ S & \to & {\tt a} S {\tt b} \mid {\tt a} {\tt b} \end{array}$$

- L'insieme iniziale di item è  $I_0 = CLOSURE\{S' \rightarrow \cdot S\} = \{S' \rightarrow \cdot S, S \rightarrow \cdot \mathtt{a}S\mathtt{b}, S \rightarrow \cdot \mathtt{ab}\}.$
- ullet I simboli immediatamente a destra del punto in  $I_0$  sono S e a, per cui calcoliamo i due insiemi:
  - $I_1 = GOTO(I_0, S) = \{S' \to S \cdot \};$
  - $\bullet \ I_2 = GOTO(I_0, \mathtt{a}) = \{S \to \mathtt{a} \cdot S\mathtt{b}, S \to \mathtt{a} \cdot \mathtt{b}, \, S \to \cdot \mathtt{a} S\mathtt{b}, S \to \cdot \mathtt{a}\mathtt{b}\}$

◆ロト ◆個ト ◆恵ト ◆恵ト ・恵 ・ から(\*)

- L'insieme  $I_1$  non dà origine ad altri insiemi di item (perché non ci sono simboli a destra del punto).
- Nel'insieme  $I_2$  ci sono tre simboli distinti a destra del punto, per cui formiamo tre insiemi:
  - $I_3 = GOTO(I_2, S) = \{S \to aS \cdot b\};$
  - $I_4 = GOTO(I_2, b) = \{S \to ab \cdot \};$
  - $\bullet \ I_5 = GOTO(I_2, \mathtt{a}) = \{S \to \mathtt{a} \cdot S\mathtt{b}, S \to \mathtt{a} \cdot \mathtt{b}, \, S \to \cdot \mathtt{a}S\mathtt{b}, S \to \cdot \mathtt{ab}\}.$
- Tuttavia,  $I_5$  viene "scartato", in quanto coincide con  $I_2$ .
- Infine lavorando su  $I_3$  si ottiene ("riusando" il simbolo  $I_5$ ):
  - $I_5 = GOTO(I_3, b) = \{S \rightarrow aSb \cdot \}.$

• Ricapitolando, gli insiemi LR(0) di item associati alla grammatica sono:

$$I_0: S' 
ightarrow S \ S 
ightarrow \mathtt{a} S\mathtt{b} \ S 
ightarrow \mathtt{a} \mathtt{b} \ I_4: S 
ightarrow \mathtt{a} \mathtt{b} .$$

$$I_1: S' \to S$$
  $I_5: S \to aSb$ 

$$I_2: S 
ightarrow \mathbf{a} \cdot S\mathbf{b} \ S 
ightarrow \mathbf{a} \cdot \mathbf{b} \ S 
ightarrow \mathbf{a} S\mathbf{b} \ S 
ightarrow \cdot \mathbf{a} \mathbf{b}$$

• Da ultimo, consideriamo la costruzione degli insiemi di item LR(0) per la grammatica aumentata

$$\begin{array}{cccc} E' & \rightarrow & E \\ E & \rightarrow & E+T \mid T \\ T & \rightarrow & T \times F \mid F \\ F & \rightarrow & (E) \mid \mathbf{n} \end{array}$$

che, ricordiamo, non è adatta al parsing top-down.

 Nella slide seguente presentiamo direttamente la collezione degli insiemi di item ottenuta applicando l'algoritmo di costruzione degli insiemi di item.

$$I_0: E' \rightarrow \cdot E \qquad I_4: F \rightarrow (\cdot E) \qquad I_7: T \rightarrow T \times \cdot F \\ E \rightarrow \cdot E + T \qquad E \rightarrow \cdot E + T \qquad F \rightarrow \cdot (E) \\ E \rightarrow \cdot T \qquad E \rightarrow \cdot T \qquad F \rightarrow \cdot \mathbf{n} \\ T \rightarrow \cdot T \times F \qquad T \rightarrow \cdot T \times F \\ T \rightarrow \cdot F \qquad T \rightarrow \cdot F \qquad I_8: E \rightarrow E \cdot + T \\ F \rightarrow \cdot (E) \qquad F \rightarrow \cdot \mathbf{n} \qquad I_9: E \rightarrow E + T \cdot \\ E \rightarrow E \cdot + T \qquad I_5: F \rightarrow \mathbf{n} \cdot \qquad T \rightarrow T \times F \cdot \\ E \rightarrow E \rightarrow T \cdot \qquad T \rightarrow T \times F \qquad T \rightarrow T \times F \cdot \\ I_2: E \rightarrow T \cdot \qquad T \rightarrow T \times F \qquad T \rightarrow \cdot T \times F \cdot \\ T \rightarrow T \cdot \times F \qquad T \rightarrow \cdot F \qquad I_{11}: F \rightarrow (E) \cdot \\ F \rightarrow \cdot (E) \qquad F \rightarrow \cdot \mathbf{n} \qquad I_{11}: F \rightarrow (E) \cdot \\ I_{12}: T \rightarrow F \cdot \qquad F \rightarrow \cdot \mathbf{n} \qquad I_{11}: F \rightarrow (E) \cdot \\ I_{12}: T \rightarrow F \cdot \qquad F \rightarrow \cdot \mathbf{n} \qquad I_{11}: F \rightarrow (E) \cdot \\ I_{12}: F \rightarrow \cdot \mathbf{n} \qquad I_{11}: F \rightarrow (E) \cdot \\ I_{12}: F \rightarrow \cdot \mathbf{n} \qquad I_{12}: F \rightarrow \cdot \mathbf{n} \qquad I_{13}: F \rightarrow (E) \cdot \\ I_{14}: F \rightarrow \cdot \mathbf{n} \qquad I_{15}: F \rightarrow \mathbf{n} \rightarrow \mathbf{n} \qquad I_{15}: F \rightarrow \mathbf{n} \rightarrow \mathbf{n} \rightarrow \mathbf{n}$$

◆□▶ ◆周▶ ◆三▶ ◆三▶ ● めの○

#### Automa LR(0)

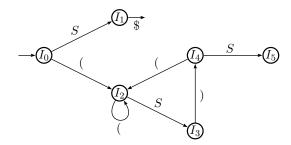
- Come già anticipato, le collezioni di item LR(0) determinate con la procedura appena descritta costituiscono gli stati dell'automa LR(0) (che, a sua volta, è alla base del parsing SLR(1) che stiamo costruendo).
- Per completare la descrizione dell'automa è necessario definire la funzione  $\delta$  di transizione.
- In realtà abbiamo già descritto tale funzione, che coincide "essenzialmente" con la funzione GOTO.
- Si noti che, tuttavia, che GOTO(I,X) "costruisce" nuovi stati e dunque J=GOTO(I,X) non viene aggiunto se risulta già definito,
- In tale caso vale comunqe  $\delta(I,X)=J$ .

ullet L'automa LR(0) per la grammatica

$$S' \rightarrow S$$

$$S \rightarrow (S)S \mid \epsilon$$

è:



#### Insiemi di item e automa

$$I_{0}: S' \to \cdot S \qquad I_{3}: S \to (S \cdot)S$$

$$S \to \cdot (S)S$$

$$S \to \cdot \qquad I_{4}: S \to (S) \cdot S$$

$$S \to \cdot (S)S$$

$$I_{1}: S' \to S \cdot \qquad S \to \cdot$$

$$I_{2}: S \to (\cdot S)S \qquad I_{5}: S \to (S)S \cdot$$

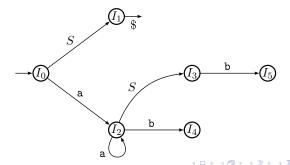
$$S \to \cdot (S)S$$

$$S \to \cdot \qquad S \to (S)S$$

ullet L'automa LR(0) per la grammatica

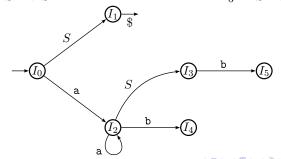
$$egin{array}{lll} S' & 
ightarrow & S \ S & 
ightarrow & { t a} S { t b} \mid { t a} { t b} \end{array}$$

è:



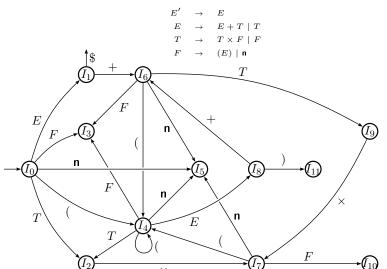
Ricordiamo anche gli insiemi di item:

$$I_0: S' o \cdot S$$
  $I_2: S o \mathtt{a} \cdot S\mathtt{b}$   $I_3: S o \mathtt{a} S \cdot \mathtt{b}$   $S o \cdot \mathtt{a} S\mathtt{b}$   $S o \mathtt{a} \cdot \mathtt{b}$   $S o \cdot \mathtt{a} S\mathtt{b}$   $S o \cdot \mathtt{a} S\mathtt{b}$   $S o \cdot \mathtt{a} S\mathtt{b}$   $S o \cdot \mathtt{b} S o \cdot \mathtt{a} S\mathtt{b}$   $S o \cdot \mathtt{b} S o \cdot \mathtt{b} S o \cdot \mathtt{b}$   $S o \cdot \mathtt{b} S o \cdot \mathtt{b} S o \cdot \mathtt{b}$   $S o \cdot \mathtt{b} S o \cdot \mathtt{b} S o \cdot \mathtt{b} S o \cdot \mathtt{b} S o \cdot \mathtt{b}$ 



 $I_5: S \to aSb$ 

• L'ultimo esempio è per la grammatica



#### Gli insiemi di item

$$I_0: E' \rightarrow \cdot E \qquad I_4: F \rightarrow (\cdot E) \qquad I_7: T \rightarrow T \times \cdot F \\ E \rightarrow \cdot E + T \qquad E \rightarrow \cdot E + T \qquad F \rightarrow \cdot (E) \\ E \rightarrow \cdot T \qquad E \rightarrow \cdot T \qquad F \rightarrow \cdot \mathbf{n} \\ T \rightarrow \cdot T \times F \qquad T \rightarrow \cdot T \times F \\ T \rightarrow \cdot F \qquad T \rightarrow \cdot F \qquad I_8: E \rightarrow E \cdot + T \\ F \rightarrow \cdot (E) \qquad F \rightarrow \cdot \mathbf{n} \qquad I_9: E \rightarrow E + T \cdot I_1: E' \rightarrow E \cdot I_5: F \rightarrow \mathbf{n} \cdot \qquad T \rightarrow T \times F \cdot I_2: E \rightarrow T \cdot \qquad T \rightarrow \cdot T \times F \quad I_{10}: T \rightarrow T \times F \cdot I_{11}: F \rightarrow \cdot (E) \cdot I_{11}: F \rightarrow \cdot (E)$$

 $I_3: T \to F$ 

◆□▶ ◆周▶ ◆三▶ ◆三▶ ● めの○

#### Item validi per un prefisso ammissibile

- Come può l'automa LR(0) aiutare a risolvere il "dilemma" shift-reduce, ovvero aiutare nel riconoscimento delle handle?
- $\bullet$  Consideriamo una generica grammatica G e consideriamo un prefisso ammissibile  $\alpha\beta_1$
- Ricordiamo per comodità che questo vuol dire che esiste una derivazione canonica destra  $S \stackrel{*}{\Rightarrow} \gamma$  tale che  $\alpha \beta_1$  è un prefisso di  $\gamma$  che termina non oltre la handle presente in  $\gamma$  (o la handle più a destra, se in  $\gamma$  ce n'è più d'una e dunque la grammatica è ambigua)
- Un item  $Z \to \beta_1 \cdot \beta_2$  si dice *valido* per  $\alpha\beta_1$  se esiste una derivazione canonica destra  $S \stackrel{*}{\Rightarrow} \alpha Z w \Rightarrow \alpha\beta_1\beta_2 w$ , dove Z è il nonterminale più a destra e dunque w è una stringa di soli terminali
- In altri termini, un item è valido per un prefisso ammissibile, se i simboli che precedono il puntino sono anche gli ultimi del prefisso

## Item validi e automa LR(0)

- Un risultato fondamentale nella teoria del parsing LR (che non dimostriamo) è il seguente
- Gli item validi per un prefisso ammissibile  $\gamma$  sono esattamente gli item che formano la collezione dello stato I che si raggiunge a partire dallo stato iniziale seguendo la sequenza di transizioni etichettate con  $\gamma$
- ullet Con riferimento alla grammatica  $G_{AB}$ , consideriamo, ad esempio, il prefisso ammissibile  $\gamma={f a}A{f b}$
- ullet La sequenza di transizioni etichettate con i simboli di  $\gamma$  conduce dallo stato iniziale  $I_0$  allo stato  $I_3$
- $\bullet$  Gli item validi per  $\gamma$  sono quindi precisamente i quattro item che formano la "collezione"  $I_3$
- Che questi siano validi è verificato nella prossima slide

## Item validi e automa LR(0)

- Per ogni item della forma  $Z\Rightarrow \beta_1\cdot\beta_2$ , mostriamo che esiste una derivazione canonica destra  $S\stackrel{*}{\Rightarrow} \alpha Zw\Rightarrow \alpha\beta_1\beta_2 w$  in cui  $\alpha\beta_1=\mathbf{a}A\mathbf{b}$ 
  - **1** Per l'item  $B \to \mathbf{b} \cdot$  abbiamo la derivazione canonica destra

$$A' \Rightarrow A \Rightarrow \mathbf{a}AB \Rightarrow \mathbf{a}A\mathbf{b}$$

e possiamo porre  $\alpha = \mathbf{a}A$ ,  $\beta_1 = \mathbf{b}$  e chiaramente  $\beta_2 = \epsilon$ 

② Per l'item  $B \rightarrow \mathbf{b} \cdot B$  abbiamo invece la derivazione

$$A' \Rightarrow A \Rightarrow \mathbf{a}AB \Rightarrow \mathbf{a}A\mathbf{b}B$$

in cui ancora  $\alpha=\mathbf{a}A$ ,  $\beta_1=\mathbf{b}$  ma  $\beta_2=B$ 

**1** Per l'item  $B \rightarrow \mathbf{b}$  abbiamo invece

$$A' \Rightarrow A \Rightarrow \mathbf{a}AB \Rightarrow \mathbf{a}A\mathbf{b}B \Rightarrow \mathbf{a}A\mathbf{b}\mathbf{b}$$

con 
$$\alpha = \mathbf{a}A\mathbf{b}$$
,  $\beta_1 = \epsilon$  e  $\beta_2 = \mathbf{b}$ 

**4** Infine, per l'item  $B \rightarrow \mathbf{b}B$  abbiamo la derivazione

$$A' \Rightarrow A \Rightarrow \mathbf{a}AB \Rightarrow \mathbf{a}A\mathbf{b}B$$

in cui  $\alpha = \mathbf{a}A$   $\beta_1 = \epsilon$  w  $\beta_2 = \mathbf{b}B$ .

#### Item validi per un prefisso ammissibile

- Sapere che un item  $Z \to \beta_1 \cdot \beta_2$  è valido per  $\alpha \beta_1$  rappresenta un'informazione importante, anche se non decisiva, per stabilire se operare lo shift oppure eseguire una riduzione
- Intanto osserviamo che non siamo interessati a tutti i prefissi ammissibili
- Di fatto ci interessano solo i prefissi che possiano trovare sullo stack
- Se il prefisso  $\alpha\beta_1$  si trova sullo stack:
  - se  $\beta_2 \neq \epsilon$  allora la handle non è ancora tutta sullo stack e dunque l'operazione da fare è eseguire uno shift;
  - viceversa, se  $\beta_2=\epsilon$ , allora la handle è già sullo stack e l'operazione da compiere è la riduzione con la produzione  $Z\to\beta_1$
- Bisogna però considerare che per un dato prefisso potrebbe esserci più di un item valido
- ullet Vediamo ancora l'esempio della collezione  $I_3$  per la grammatica  $G_{AB}$

Mauro Leoncini Compilatori Anno Accademico 2024/25 56/69

## Item validi e automa LR(0)

- Analizziamo dunque gli item in  $I_3$  uno per uno, ricordando che il prefisso è  $\gamma = \mathbf{a}A\mathbf{b}$ 
  - ① Item  $B \to \mathbf{b}$ . La presenza di questo item imporrebbe una riduzione con la produzione  $B \to \mathbf{b}$
  - ② Item  $B \to \mathbf{b} \cdot B$ . In questo caso  $\beta_1 = \mathbf{b}$  e  $\beta_2 = B$ . Questo item "chiama" uno shift
  - **3** Item  $B \to \mathbf{b}$ . Qui  $\beta_1 = \epsilon$  e  $\beta_2 = \mathbf{b}$ . Anche questo item chiama uno shift.
  - **1** Item  $B \to \mathbf{b}B$ . Qui  $\beta_1 = \epsilon$  e  $\beta_2 = \mathbf{b}B$ . E anche in questo caso viene chiamato uno shift

## Costruzione della tabella di parsing SLR(1)

- La situazione illustrata nella precedente diapositiva sembra lasciare ancora aperto il problema della decisione shift/reduce
- Ci sono però alcune considerazioni da fare
- Innanzitutto, osserviamo che se una collezione include un item del tipo  $Z \to \alpha \cdot A \gamma$ , cioè un item in cui il puntino precede un nonterminale, allora a seguito dell'operazione di chiusura, la collezione conterrà anche un item del tipo  $W \to \cdot x \delta$ , cioè un item in cui il puntino precede un terminale (è immediato rendersene conto)
- In secondo luogo non abbiamo ancora tenuto conto dell'input!
- Si rifletta sul fatto che l'automa che abbiamo definito è indicato come "automa LR(0)" proprio perché nella sua costruzione l'input non viene preso in considerazione
- Nella costruzione del parser SLR(1), a partire dall'automa LR(0), prendiamo finalmente in considerazione un carettere di lookahead

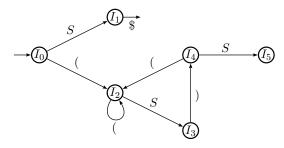
## Tabelle di parsing SLR(1)

- Le tabelle di parsing SLR(1), di cui ora diamo l'algoritmo di costruzione, incorporano le informazioni contenute nell'automa, oltre ad altre informazioni
- ullet Fra le informazioni importanti, non considerate nell'automa, un ruolo fondamentale è costituito dalla conoscenza dell'insieme di simboli FOLLOW(A), per ogni simbolo non terminale A della grammatica
- Le tabelle hanno tante righe quanti sono gli stati dell'automa e un numero di colonne pari al vocabolario della grammatica
- Le colonne sono suddivise in due parti, corrispondenti ai simboli terminali e nonterminali, chiamate rispettivamente parte ACTION e parte GOTO
- L'algoritmo esamina gli stati dell'automa e le transizioni uscenti da ciascuno stato

## Tabelle di parsing SLR(1)

- ullet Per ogni stato  $I_j$ , consideriamo le transizioni uscenti.
- Se esiste una transizione da  $I_j$  a  $I_k$  etichettata  $X \in \mathcal{T}$  poniamo  $ACTION\left[j,X\right] = \text{shift } k.$
- Se esiste una transizione da  $I_j$  a  $I_k$  etichettata  $X \in \mathcal{N}$  poniamo  $GOTO\left[j,X\right] = k.$
- Se nell'insieme di item corrispondenti a  $I_j$  esiste un item  $A \to \alpha$ , allora poniamo  $ACTION\ [j,X] = {\sf reduce}\ A \to \alpha$  per tutti i simboli X in  $FOLLOW\ (A)$ .
- ullet Se  $I_j$  contiene l'item  $\mathcal{S}' o \mathcal{S}\cdot$  si pone  $ACTION[j,\$] = \mathsf{accept}.$
- Se, in base a quanto sopra, in una posizione della tabella viene inserito più di un dato, allora la grammatica non è SLR(1)
- I conflitti, esclusivamente nella parte ACTION, possono essere di tipo shift-reduce

# Esempio (grammatica per le parentesi)



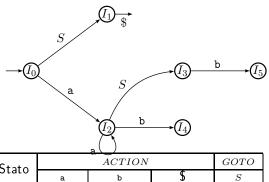
Stato		GOTO		
Jiaio	(	)	\$	S
0	shift 2	reduce 2	reduce 2	1
1			accept	
2	shift 2	reduce 2	reduce 2	3
3		shift 4		
4	shift 2	reduce 2	reduce 2	5
5		reduce 1	reduce 1	

Mauro Leoncini Compilatori Anno Accademico 2024/25 61/

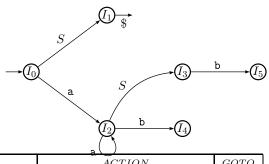
- Riconsideriamo la grammatica
  - $S \rightarrow \mathtt{a} S\mathtt{b}$  Produzione 1
  - $S \rightarrow {\tt ab}$  Produzione 2

in cui abbiamo numerato (arbitrariamente) le produzioni.

- Per tale grammatica l'algoritmo appena delineato produce la tabella di parsing evidenziata nella seguente diapositiva (in cui riportiamo, per comodità, anche l'automa LR(0)).
- È immediato anche verificare che  $FOLLOW(S) = \{\$, b\}$



Stato		GOTO		
Stato	a	Ъ	\$	S
0	shift 2			1
1			accept	
2	shift 2	shift 4		3
3		shift 5		
4		reduce 2	reduce 2	
5		reduce 1	reduce 1_	

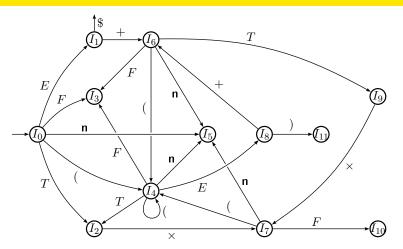


a\_/						
Stato		GOTO				
Stato	a	Ъ	\$	S		
0	shift 2			1		
1			accept			
2	shift 2	shift 4		3		
3		shift 5				
4		reduce 2	reduce 2			
5		reduce 1	reduce 1_			

• Consideriamo il comportamento del parser su input aabb

Stack	Input	Azione
\$0	aabb\$	shift 2
\$02	abb $\$$	shift 2
\$022	bb\$	shift 4
\$0224	<b>b</b> \$	$reduce\; S  o \mathtt{ab}$
\$023	<b>b</b> \$	shift 5
\$0235	\$	$reduce\; S  o \mathtt{a} S \mathtt{b}$
\$01	\$	accept

## Ricordiamo l'automa per la grammatica delle espressioni



- $FOLLOW(E) = \{\$, \}, +\}$
- FOLLOW(T) = FOLLOW(F) = {\$, \, +, \*}

Diamo infine la tabella di parsing per la grammatica

Stato	ACTION						GOT	0	
Stato	n	+	×	(	)	\$	E	T	F
0	s 5			s 4			1	2	3
1		s 6				accept			
2		r 2	s 7		r 2	r 2			
3		r 4	r 4		r 4	r 4			
4	s 5			s 4			8	2	3
5		r 6	r 6		r 6	r 6			
6	s 5			s 4				9	3
7	s 5			s 4					10
8		s 6			s 11				
9		r 1	s 7		r 1	r 1			
10		r 3	r 3		r 3	r 3			
11		r 5	r 5		r 5	r 5			

ullet Consideriamo il comportamento del parser su input  ${f n} imes ({f n} + {f n})$ 

Stack	Input	Azione
\$0	$n \times (n+n)$ \$	shift 5
\$0.5	$\times (n+n)$ \$	reduce $F \rightarrow n$
\$03	$\times (n+n)$ \$	reduce $T \rightarrow F$
\$0.2	$\times (n+n)$ \$	shift 7
\$0 2 7	(n+n)\$	shift 4
\$0 2 7 4	n+n)\$	shift 5
\$0 2 7 4 5	+n)\$	reduce $F \rightarrow n$
\$0 2 7 4 3	+n)\$	reduce $T \rightarrow F$
\$0 2 7 4 2	+n)\$	reduce $E \rightarrow T$
\$0 2 7 4 8	+n)\$	shift 6
\$0 2 7 4 8 6	n)\$	shift 5
\$0 2 7 4 8 6 5	)\$	reduce $F \rightarrow n$
\$0 2 7 4 8 6 3	)\$	reduce $T \rightarrow F$
\$0 2 7 4 8 6 9	)\$	reduce $E \rightarrow E + T$
\$0 2 7 4 8	)\$	shift 11
\$0 2 7 4 8 11	\$	reduce $F \rightarrow (E)$
\$0 2 7 10	\$	reduce $T \rightarrow T \times F$
\$0.2	\$	reduce $E{ ightarrow}T$
\$0.1	\$	accept